

Venture Capital en Biomedicina

Informe de Inteligencia de Negocio y Data Science

DEFENSA DE PROYECTO FINAL

Diagnóstico Inicial

CONTEXTO Y OBJETIVO

Evaluar la integridad del dataset original de Crunchbase (más de 66.000 registros) para definir la estrategia de limpieza y tratamiento.

CONCLUSIÓN EJECUTIVA

La alta fragmentación y la presencia de nulos críticos hacen imposible un análisis estadístico directo. Se requiere una purga profunda para no distorsionar las métricas.

```
df = pd.read_csv('startups_dataset.csv')

print(f"Dimensiones del dataset: {df.shape[0]} filas y {df.shape[1]} columnas.\n")

print("--- TIPOS DE DATOS ---")
print(df.dtypes)
print("\n")

print("--- VOLUMEN DE VALORES NULOS POR COLUMNA ---")
nulos = df.isnull().sum()
print(nulos[nulos > 0].sort_values(ascending=False))
```

Dimensiones del dataset: 66368 filas y 14 columnas.

Limpieza de Inversión

CONTEXTO Y OBJETIVO

Transformar las rondas confidenciales (representadas con guiones '-') en valores nulos matemáticos (NaN).

CONCLUSIÓN EJECUTIVA

Se garantiza el rigor financiero absoluto. Asumir que esas startups levantaron 0 dólares habría hundido artificialmente las medias monetarias del ecosistema global.

```
maskara_guiones = (df['funding_total_usd'] == '-')
df.loc[maskara_guiones, 'funding_total_usd'] = np.nan

df['funding_total_usd'] = df['funding_total_usd'].astype(float)

print("---- ESTADÍSTICA DE FINANCIACIÓN (declarada) ----")
print(df['funding_total_usd'].describe())
```

Series Temporales

CONTEXTO Y OBJETIVO

Estandarizar las columnas de texto plano que contienen fechas a formato Datetime oficial de Pandas, forzando la corrección de errores (coerce).

CONCLUSIÓN EJECUTIVA

La conversión exitosa cimentó la base técnica indispensable para medir los ciclos reales de maduración y la tracción histórica posterior.

```
df['founded_at'] = pd.to_datetime(df['founded_at'], errors='coerce')
df['first_funding_at'] = pd.to_datetime(df['first_funding_at'], errors='coerce')

print("Tipo de 'founded_at':", df['founded_at'].dtypes)
print("Tipo de 'first_funding_at':", df['first_funding_at'].dtypes)
```

```
Tipo de 'founded_at': datetime64[ns]
Tipo de 'first_funding_at': datetime64[ns]
```

Aislamiento de Nicho

CONTEXTO Y OBJETIVO

Aislar de forma exclusiva el ecosistema de salud usando operadores lógicos sobre el catálogo de categorías globales.

CONCLUSIÓN EJECUTIVA

Se redujo con éxito el ruido del mercado mundial, logrando un *core* hiper-segmentado de **7.824 startups** estrictamente médicas y biotecnológicas.

```
df['category_list'] = df['category_list'].fillna('Desconocido')

mascara_bio = df['category_list'].str.contains('Biotechnology')
mascara_salud = df['category_list'].str.contains('Health Care')
mascara_medica = df['category_list'].str.contains('Medical')

df_salud = df[mascara_bio | mascara_salud | mascara_medica].copy()

print(df_salud.shape)
```

(7824, 14)

Sub-especialidades

CONTEXTO Y OBJETIVO

Extraer un catálogo único de disciplinas procesando el múltiple etiquetado corporativo mediante la estructura de datos `set`.

CONCLUSIÓN EJECUTIVA

El mercado de inversión en salud se compone de **434 nichos** especializados, demostrando una alta diversificación técnica.

```
especialidades_unicas = set()
lista_categorias = df_salud['category_list'].tolist()

for fila in lista_categorias:
    elementos = fila.split('|')
    for especialidad in elementos:
        especialidades_unicas.add(especialidad)

print(len(especialidades_unicas))
print(list(especialidades_unicas)[:10])
```

434

['Clinical Trials', 'Data Integration', 'Bitcoin', 'Contact Management', 'FinTech', 'App Marketing', 'Virtual Worlds', 'Marketing Automation', 'SaaS', 'Entertainment']

Densidad y Competencia

CONTEXTO Y OBJETIVO

Cuantificar la saturación del mercado empleando diccionarios iterativos para mapear dónde se agrupa el apetito inversor.

CONCLUSIÓN EJECUTIVA

Biotecnología (4.562) y **Health Care (2.385)** dominan absolutamente la competencia, aglutinando la inmensa mayoría de las fundaciones tecnológicas.

```
frecuencias_especialidades = {}
lista_categorias = df_salud['category_list'].tolist()

for fila in lista_categorias:
    elementos = fila.split('|')
    for especialidad in elementos:
        if especialidad in frecuencias_especialidades:
            frecuencias_especialidades[especialidad] = frecuencias_especialidades[especialidad] + 1
        else:
            frecuencias_especialidades[especialidad] = 1

serie_frecuencias = pd.Series(frecuencias_especialidades)
top_5_nichos = serie_frecuencias.sort_values(ascending=False).head(5)

print("--- TOP 5 NICHOS CON MÁS STARTUPS ---")
print(top_5_nichos)
```

```
--- TOP 5 NICHOS CON MÁS STARTUPS ---
Biotechnology      4562
Health Care        2385
Medical            1203
Health and Wellness  609
Medical Devices    566
dtype: int64
```

Estado de Supervivencia

6.212

OPERATING

465 / 584

CLOSED / IPO

```
supervivencia_salud = df_salud.groupby('status').size()
supervivencia_ordenada = supervivencia_salud.sort_values(ascending=False)
print(supervivencia_ordenada)
```

```
status
operating    6212
ipo          584
acquired     563
closed       465
```

CONTEXTO Y OBJETIVO

Evaluar el riesgo estructural del Venture Capital agrupando startups por su estado operativo actual (*status*).

CONCLUSIÓN EJECUTIVA

Se constata empíricamente el altísimo riesgo inherente del sector científico, con una inmensa base consumiendo capital operativo y un riguroso embudo hacia la salida rentable.

Distribución Global


CONTEXTO Y OBJETIVO

Mapear la hegemonía geopolítica sumando el capital total captado por cada país de origen.

CONCLUSIÓN EJECUTIVA

Estados Unidos ejerce un dominio absoluto e incomparable. Obliga a cualquier proyecto biomédico con afán de escalabilidad internacional a pivotar forzosamente hacia su mercado.


```
inversion_por_pais = df_salud.groupby('country_code')['funding_total_usd'].sum()
top_5_paises = inversion_por_pais.sort_values(ascending=False).head(5)
print(top_5_paises)
```



Biotech vs. Salud Tradicional

CONTEXTO Y OBJETIVO

Contrastar la exigencia de inversión media requerida entre la biotecnología pura y la salud tradicional.



■ Biotech (I+D/Farma): \$28.9M media

■ Salud Tradicional: \$17.1M media

```
df_salud['nicho_principal'] = 'Health/Medical Tradicional'

mascara_biotech_pura = df_salud['category_list'].str.contains('Biotechnology')
df_salud.loc[mascara_biotech_pura, 'nicho_principal'] = 'Biotech (I+D / Farma)'

comparativa_costes_medios = df_salud.groupby('nicho_principal')['funding_total_usd'].mean()

print("--- COSTE MEDIO DE DESARROLLO POR NICHOS ---")
print(comparativa_costes_medios.map('${:,.2f}'.format))
```

nicho_principal	funding_total_usd
Biotech (I+D / Farma)	\$28,909,143.20
Health/Medical Tradicional	\$17,171,699.26

CONCLUSIÓN EJECUTIVA

Los datos empíricos validan que el I+D farmacológico demanda inyecciones de capital casi duplicadas debido a patentes y regulación, frente a la escalabilidad ágil del software médico.

Tasa de Éxito (IPO)

7.46%

SECTOR SALUD

1.64%

RESTO GLOBAL

CONTEXTO Y OBJETIVO

Cruzar el rendimiento de salidas a bolsa (IPO) de nuestro nicho aislado frente al volumen del mercado global generalista.

CONCLUSIÓN EJECUTIVA

Pese a los formidables costes de entrada y el riesgo latente, la medicina compensa a los inversores otorgando una probabilidad de maduración bursátil que **cuadruplica** al resto de industrias.

```
total_salud = len(df_salud)
ipo_salud = len(df_salud[df_salud['status'] == 'ipo'])
porcentaje_exito_salud = (ipo_salud / total_salud) * 100

df_resto = df[~df['category_list'].str.contains('Biotechnology|Health Care|Medical', na=False)]
total_resto = len(df_resto)
ipo_resto = len(df_resto[df_resto['status'] == 'ipo'])
porcentaje_exito_resto = (ipo_resto / total_resto) * 100

print(f"Éxito (IPO) en Sector Salud: {porcentaje_exito_salud:.2f}%")
print(f"Éxito (IPO) en Resto del Mercado: {porcentaje_exito_resto:.2f}%")
```

Éxito (IPO) en Sector Salud: 7.46%
Éxito (IPO) en Resto del Mercado: 1.64%

Reloj de la Innovación

CONTEXTO Y OBJETIVO

Calcular la maduración (días hasta primera ronda) y sanear anomalías temporales (registros con valores negativos).

CONCLUSIÓN EJECUTIVA

La limpieza de rondas *pre-constitución legal* permite obtener una radiografía exacta y sin distorsiones del inmenso ciclo de letargo en la ciencia médica.

```
df_salud['dias_hasta_inversion'] = (df_salud['first_funding_at'] - df_salud['founded_at']).dt.days

mascara_negativos = df_salud['dias_hasta_inversion'] < 0
df_salud.loc[mascara_negativos, 'dias_hasta_inversion'] = np.nan

print(df_salud[['name', 'dias_hasta_inversion']].dropna().head())
```

	name	dias_hasta_inversion
6	Ondine Biomedical Inc.	4636.0
30	Redox	145.0
40	10X Genomics	1107.0
41	10X Technologies	311.0
53	121nexus	122.0

Evolución Histórica

CONTEXTO Y OBJETIVO

Agrupar las fundaciones por año para trazar empíricamente la línea de crecimiento acelerado del ecosistema biomédico.

CONCLUSIÓN EJECUTIVA

Se ratifica un *boom* entre 2010 y 2013, seguido de un declive que obedece al '**modo oculto**' (**Stealth Mode**): las biotecnológicas operan años antes de registrar rondas públicas.

```
df_salud['año_fundacion'] = df_salud['founded_at'].dt.year  
  
nacimientos_por_año = df_salud.groupby('año_fundacion').size()  
  
nacimientos_recientes = nacimientos_por_año.sort_index(ascending=False)  
  
print(nacimientos_recientes.head(10))
```

año_fundacion	
2016.0	1
2015.0	85
2014.0	308
2013.0	447
2012.0	455
2011.0	431
2010.0	412
2009.0	374
2008.0	325
2007.0	341


Eficiencia de Capital

CONTEXTO Y OBJETIVO

Crear el KPI 'Ticket Medio por Ronda' aplicando matemáticas defensivas para localizar startups hiper-eficientes o anomalías.

CONCLUSIÓN EJECUTIVA

Exigir que las rondas sean mayores a cero evita divisiones por infinito que destruirían los gráficos predictivos, permitiendo localizar líderes que captan cifras astronómicas por iteración.



```
mascara_rondas_validas = df_salud['funding_rounds'] > 0
df_salud.loc[mascara_rondas_validas, 'ticket_medio_por_ronda'] = df_salud['funding_total_usd'] / df_salud['funding_rounds']

top_3 = df_salud[['name', 'ticket_medio_por_ronda', 'funding_rounds']].sort_values(by='ticket_medio_por_ronda', ascending=False).head(3).copy()
top_3['ticket_medio_por_ronda'] = top_3['ticket_medio_por_ronda'].map('${:,.2f}'.format)

print("--- TOP 3 STARTUPS CON MAYOR TICKET MEDIO POR RONDA ---")
print(top_3)
```

--- TOP 3 STARTUPS CON MAYOR TICKET MEDIO POR RONDA ---

	name	ticket_medio_por_ronda	funding_rounds
12238	COFCO	\$3,200,000,000.00	1
9831	Carestream	\$2,400,000,000.00	1
9701	Cardinal Health	\$1,500,000,000.00	1

Unicornios y Camino IPO

```
max_inversion = df_salud['funding_total_usd'].max()

mascara_max = df_salud['funding_total_usd'] == max_inversion
unicornio = df_salud[mascara_max]

print(unicornio[['name', 'funding_total_usd', 'country_code']])
print("\n")

df_ipo = df_salud[df_salud['status'] == 'ipo']
lista_rondas = df_ipo['funding_rounds'].tolist()

suma_rondas = 0
contador = 0

for rondas in lista_rondas:
    suma_rondas = suma_rondas + rondas
    contador = contador + 1

if contador > 0:
    media_rondas = suma_rondas / contador
else:
    media_rondas = 0

print(media_rondas)
```

	name	funding_total_usd	country_code
12238	COFCO	3.200000e+09	CHN

3.414383561643836

CONTEXTO Y OBJETIVO

Localizar al líder absoluto de captación (Techo Financiero) y procesar las rondas medias ejecutadas por la élite bursátil.

CONCLUSIÓN EJECUTIVA

COFCO domina como outlier de soberanía corporativa. Además, se constata que el mercado asume una media de dilución de ~3.4 rondas antes de tolerar una IPO.

LÍDER GLOBAL

COFCO

\$3.200M

Despliegue BBDD (SQL)

CONTEXTO Y OBJETIVO

Filtrar las entidades viables y consolidar el dataset analítico para su integración en entornos relacionales corporativos.

CONCLUSIÓN EJECUTIVA

La depuración dimensional y la anulación de índices internos entregan un "**Gold Dataset**" inmaculado, apto para su consumo directo por Arquitectos de Datos y herramientas BI.

```
maskara_viable = df_salud['status'].isin(['operating', 'ipo', 'acquired'])

columnas_sql = [
    'name',
    'category_list',
    'funding_total_usd',
    'status',
    'country_code',
    'funding_rounds',
    'dias_hasta_inversion'
]

df_sql = df_salud[maskara_viable][columnas_sql].copy()

df_sql.to_csv('startups_salud_gold.csv', index=False)

print(df_sql.info())
```


Conclusiones Finales

- ✓ **Rigor Matemático Crítico:** Omitir anomalías o no sanear valores nulos deforma drásticamente los modelos. Limpiar el dato no es estética, es el núcleo de la exactitud predictiva en Data Science.
- ✓ **Alta Barrera, Alta Recompensa:** El ecosistema de salud exige inversiones masivas, pero su tasa de maduración hacia la bolsa (IPO) compensa ampliamente el riesgo estructural frente a otros nichos.
- ✓ **Evolución y Escalabilidad:** El capital está altamente concentrado (Geográficamente en EE.UU. y Sectorialmente en Biotecnología pura). Competir a escala global requiere alinear estratégicamente la captación con dichas densidades.